
Prédiction Churn

Machine Learning appliqué à la rétention client

Présenté par: Amina Abid

Atelier Pratique : E-commerce de Cadeaux

Sommaire

1. Problématique & enjeux

2. Données & EDA

3. Préprocessing & Feature Engineering

4. Modélisation & Résultats


5. Segmentation & Optimisation

6. Interprétabilité

7. Déploiement & Validation

8. Conclusion & Perspectives

Problematique et Enjeux



Le churn : un défi stratégique majeur

Comprendre pourquoi les clients quittent la plateforme est essentiel pour la survie à long terme de l'entreprise.



Objectif : identifier les clients à risque avant leur départ

Utiliser le Machine Learning pour anticiper les comportements de désabonnement.



Permettre des actions de rétention ciblées

Optimiser les budgets marketing en se concentrant sur les segments les plus critiques.


Coût d'acquisition vs fidélisation

5-7x


plus cher d'acquérir
un nouveau client

Dataset et Statistiques Cles

Répartition churn



Couverture pays



4 372
clients




52
features



Classification binaire supervisée
Problème de prédiction

Exploration des Données EDA



Analyse RFM

Recency, Frequency, Monetary

Corrélations

Corrélations fortes identifiées

Data Leakage

Détecté et corrigé

Valeurs Manquantes


Analyse des valeurs manquantes dans le dataset.

Colonne	Manquantes	Pourcentage %
AvgDaysBetweenPurchases	79	1.81%
Age	1311	29.99%

⌘ Stratégie d'imputation


Imputation par la médiane pour les variables numériques afin de préserver la distribution tout en gérant les valeurs aberrantes potentielles.

Pourcentage de valeurs manquantes par colonne



Age est la colonne la plus impactée avec 29.99% de données manquantes.

Pipeline de Préprocessing (9 étapes)



Nettoyage des Donnees

Étape critique du prétraitement : identification et suppression des variables introduisant un **data leakage** ou non pertinentes.

Non-prédictives

- **CustomerID** : identifiant sans pouvoir prédictif
- **NewsletterSubscribed** : constante ('Yes')
- **LastLoginIP** : remplacée par dérivés

Redondantes

- **UniqueInvoices** = Frequency (1.00)
- **CancelledTransactions** = NegativeQuantityCount
- **Multicolinéarité ($|\rho| > 0.9$)** : MonetaryMin, MonetaryMax, MonetaryStd

Variables supprimées pour Data Leakage

- **ChurnRiskCategory** : 'Critique' = 100% churn
- **CustomerType** : 'Perdu' = clients churnés
- **Recency** : $\rho = 0.86$ avec churn
- **FavoriteSeason** : Automne $\approx 98\%$ non-churn
- **RFMSegment, LoyaltyLevel**
- **FirstPurchaseDaysAgo**
- **CustomerTenureDays, Age**
- **UniqueCountries, AgeCategory**

Bilan Final

Total : 18 colonnes supprimées

Passage de 52 à 34 variables

Data Leakage - Détection et Correction

Qu'est-ce que le Data Leakage ?

Variables qui révèlent indirectement la cible et faussent les performances du modèle. C'est une fuite d'information du futur vers le passé.

Impact sur les performances

Modèle Initial

AUC 0.99

(Faux Positif)



Modèle Corrigé

AUC 0.89

(Réaliste)

Colonnes supprimées (18 au total)

- **CustomerId** : Identifiant unique
- **ChurnLabel** : Cible, fuite directe
- **ChurnScore** : Score prédictif, fuite
- **ChurnReason** : Raison du départ, fuite
- **ChurnDate** : Date de départ, fuite
- + 13 autres colonnes corrélées



Bonne pratique : fit uniquement sur train, jamais sur test.

Validation Rigoureuse

Parsing des Dates

La colonne **RegistrationDate** existe en plusieurs formats inconsistants (ISO, DD/MM/YYYY, MM/DD/YYYY, variantes à 2 chiffres).

La fonction `parse_dates()` unifie ces formats avec détection par règle explicite.

"Cette standardisation permet une exploitation cohérente des informations temporelles."

Extraction de 6 nouvelles features :

RegMonth

Mois d'inscription (1–12)

RegWeekday

Jour de la semaine (0=Lundi)

RegIsWeekend

Binaire : inscription un weekend

AccountAgeDays

Ancienneté du compte en jours

IsNewClient

Binaire : compte < 1 an

RegSeason

Saison d'inscription

Feature Engineering

Nouvelles features créées :

AvgBasketValue

Valeur moyenne par transaction

CancellationRate

Taux d'annulation

SpendingVolatility

Instabilité des dépenses

EngagementScore

Satisfaction + réclamations

ProductsPerTransaction

Diversité produits

Enrichissement du signal prédictif via le comportement transactionnel

Train/Test Split



Division Stratifiée 80/20

Séparation rigoureuse pour préserver la distribution des classes et garantir une évaluation honnête des performances.



Prévention du Data Leakage

Le split est effectué **AVANT** toute transformation (imputation, scaling) pour éviter que des informations du test ne fuient dans le train.



Maintien du Ratio Churn

Utilisation de stratify=y pour conserver le ratio churn/non-churn identique dans les deux sets.

Bonne Pratique

- **Fit uniquement sur train**
- **Transform sur train et test**

Variables : X_{train} , X_{test} , y_{train} , y_{test}

Imputation et Encodage



Imputation des Valeurs

Imputation par la **médiane** (robuste aux outliers) pour les variables numériques:
AvgDaysBetweenPurchases : 79 valeurs manquantes (1,8%) => Imputation = médiane



Variables Critiques

SatisfactionScore:

Imputation = **KNN Imputer (k = 5)**

KNN préserve les relations locales entre observations pour les variables sensibles et corrélées.

Règle d'Or

"Statistiques calculées sur train, appliquées au test."

Imputation et Encodage



Encodage Catégoriel



Encodage Ordinal

SpendingCategory: Low < Medium < High < VIP → (0,1,2,3)

BasketSizeCategory: Petit < Moyen < Grand

OrdinalEncoder avec unknown_value = -1



Target Encoding

Region: encodée par moyenne de Churn

Smoothing = 1.0 pour réduire le surapprentissage



One-Hot Encoding

(PreferredTimeOfDay) (WeekendPreference) (ProductDiversity) (Gender) (AccountStatus) (RegSeason)

Via pd.get_dummies(), colonnes alignées train/test

Synthèse

43 → 58 variables

X_train = (3497, 58) | X_test = (875, 58)

Suppression de la Multicolinéarité et Normalisation

Suppression de la Multicolinéarité

Analyse de corrélation avec seuil $|r| > 0.85$

Paire de variables	$ r $	Variable supprimée
UniqueProducts ↔ UniqueDescriptions	1.000	UniqueProducts
MonetaryMin ↔ MonetaryMax	0.995	MonetaryMin
MinQuantity ↔ MaxQuantity	0.989	MinQuantity
MonetaryStd ↔ MaxQuantity	0.981	MonetaryStd
ReturnRatio ↔ CancellationRate	0.966	CancellationRate
AvgProductsPerTransaction ↔ AvgLinesPerInvoice	0.963	AvgProductsPerTransaction
WeekendPurchaseRatio ↔ WeekendPreference	0.913	WeekendPurchaseRatio
MonetaryTotal ↔ TotalQuantity	0.900	TotalQuantity

Résultat : 10 variables supprimées → 48 features finales

Normalisation RobustScaler

Formule

$$X_{scaled} = (X - \text{médiane}) / IQR$$

Avantages

- ✓ Résistant aux outliers (basé sur les quartiles)
- ✓ Préserve la distribution des données
- ✓ *Fit* sur train uniquement (anti-leakage)

25

Colonnes numériques normalisées

23

Colonnes binaires exclues

Les variables binaires (0/1) issues du one-hot encoding sont exclues pour préserver leur interprétation.

Rééquilibrage SMOTE



SMOTE (Synthetic Minority Over-sampling Technique) génère des exemples synthétiques de la classe minoritaire (churners) en interpolant entre des exemples voisins (k=5).

Tableau comparatif des distributions

Ensemble	Avant SMOTE	Après SMOTE	Ratio Final
X_train (80 %)	{0: 2334, 1: 1163}	{0: 2334, 1: 2334}	1:1
X_test (20 %)	{0: 584, 1: 291}	inchangé	2:1



Appliqué uniquement sur train pour éviter le data leakage.

Modélisation Supervisée

Trois modèles comparés :

Régression Logistique

Modèle baseline


Random Forest

Ensemble learning

XGBoost

Meilleur

Gradient boosting optimisé



Métriques d'Évaluation

Dans ce problème de prédiction du churn, les données sont équilibrées après SMOTE mais la détection des churners reste prioritaire.



Recall

Priorité Métier

Capacité à détecter les churners (priorité métier).

Le Recall est particulièrement important car un churn non détecté = perte directe pour l'entreprise.



Precision

Fiabilité des prédictions positives.



F1-score

Compromis precision/recall.



AUC-ROC


Capacité globale de discrimination.

Résultats des Modèles

Modèle	Acc	Prec	Rec	F1	AUC
Rég. Logistique	0,70	0,53	0,89	0,66	0,85
Random Forest	0,73	0,56	0,89	0,68	0,87
XGBoost	0,81	0,68	0,81	0,74	0,89

✔ Modèle final : XGBoost (AP = 0,846)

Précision-Rappel du XGBoost





Courbe Précision-Rappel

Average Precision (AP) = **0,846**


Clustering K-Means - Choix de K

Détermination du nombre optimal de clusters k



k optimal = 5

Clustering K-Means - Résultats



C2 (VIP, 21 clients) = 0% churn | C4 (inactifs) = 72.3% churn
→ segment prioritaire pour actions de rétention immédiates | La satisfaction seule (C0 vs C1) ne discrimine pas le churn

Clustering K-Means - Résultats

Intégration comme Feature Supervisée

Configuration	F1-Score	AUC-ROC	Δ F1	Δ AUC
XGBoost sans KMeans_Cluster	0.7400	0.8892	—	—
XGBoost avec KMeans_Cluster	0.7334	0.8915	-0.007	+0.002

Conclusion

La feature **KMeans_Cluster** n'améliore pas le F1-Score ($\Delta = -0.007$) et est donc **rejetée automatiquement** par le pipeline. XGBoost est suffisamment puissant pour extraire directement les patterns de segmentation à partir des features originales (Frequency, MonetaryTotal, etc.) sans pré-segmentation explicite.

Optimisation des Hyperparamètres



GridSearchCV

Recherche exhaustive

- 144 combinaisons testées
- Exploration complète de l'espace
- Temps de calcul élevé



Optuna

Optimisation bayésienne

- 100 trials intelligents
- Apprentissage adaptatif
- Convergence rapide

Résultat Final

Optuna

F1-Score

0.73

AUC-ROC


0.89

Recall

0.89

Features les Plus Importantes

Top 5 des variables prédictives du churn



Analyse de l'Overfitting

Vérifier la capacité de généralisation


Comparer les performances train vs test : si l'écart est important, il y a surapprentissage.

Techniques anti-overfitting utilisées

- 🛡 Régularisation L1/L2
- 🛑 Early stopping
- 📦 max_depth limité
- ✂ Subsample

Conclusion sur la bonne généralisation du modèle.

Graphique comparatif barres Train vs Test



Train AUC vs Test AUC

0.92 vs 0.89

Train F1 vs Test F1

0.78 vs 0.74

Prédiction et Niveaux de Risque

Faible 0 - 25% Surveillance passive. Maintenir l'engagement standard.	Moyen 25 - 50% Campagnes de réactivation douces, newsletters ciblées.	Élevé 50 - 75% Offres promotionnelles personnalisées, coupons de réduction.	Critique 75 - 100% Intervention directe, appel service client ou remise majeure.
---	---	---	--

Exemples de prédictions (XGBoost)

Client VIP fidèle	8.7%	FAIBLE
Client moyen	40.3%	MOYEN
Client à risque	76.9%	CRITIQUE

Déploiement Application Flask

Interface de prédiction Flask

Déploiement d'une application interactive permettant de saisir les données client et d'obtenir instantanément la **probabilité de churn** et le **niveau de risque** associé.

Actions de rétention

Stratégie ciblée basée sur les segments de risque pour optimiser le budget marketing et maximiser la rétention client.

Architecture



API REST

/predict, /predict/batch



Interface Web Interactive

Dashboard de prédiction en temps réel



Pipeline de Prédiction

Identique à l'entraînement



Niveaux de Risque

Faible, Moyen, Élevé, Critique

Déploiement Application Flask

Prédiction de churn

Renseignez les données client ci-dessous.

COMPORTEMENT & TRANSACTIONS

Spending category

Fréquence (nb commandes)

High

120

Transactions

Moy. jours entre achats

Montant total (€)

3

ex: 1500

Panier moyen (€)

COMPTE & PROFIL

Ancienneté compte (jours)

Nouveau client

Diversité produits

Oui

Explorateur

Tickets support

Genre

Unknown

TEMPORALITÉ & LOCALISATION

Saison d'inscription

Mois inscription (1-12)

Jour préféré

Printemps

6

Lundi

Préférence semaine

Région

Jour inscription (0=Lun...6=Dim)

Weekend

France

6

Résultat

La prédiction apparaît ici.

✓

Churn : Non

Client stable et fidèle.

Probabilité de churn

2.8%

de probabilité de départ

Risque faible

RECOMMANDATIONS

› Client stable — maintenir la relation avec des communications régulières.

› Proposer des produits complémentaires basés sur ses achats précédents.

› Intégrer dans le programme de fidélité si ce n'est pas encore fait.

› Surveiller si la récence commence à augmenter dans prochains mois.

DONNÉES ANALYSÉES

Spending VIP

Fréquence 120 cmd

Ancienneté 78 j

Transactions 989

Support tickets

Saison automne

Panier moyen €10

Montant total €

Détecteur de churn

Renseignez les données client ci-dessous.

01 - COMPORTEMENT & TRANSACTIONS

Spending category

Fréquence (nb commandes)

High

12

Total transactions

Moy. jours entre achats

Montant total (€)

ex: 50

ex: 30

ex: 1500

Panier moyen (€)

ex: 125

02 - COMPTE & PROFIL

Ancienneté compte (jours)

Nouveau client

Diversité produits

78

Oui

Explorateur

Tickets support

Genre

ex: 2

Female

03 - TEMPORALITÉ & LOCALISATION

Saison d'inscription

Mois inscription (1-12)

Jour préféré

Printemps

6

Lundi

Préférence semaine

Région

Jour inscription (0=Lun...6=Dim)

Weekend

UK

ex: 2

Résultat

La prédiction apparaît ici.

!

Churn : Oui

Client à risque de départ.

Probabilité de churn

82.7%

de probabilité de départ

Risque élevé

RECOMMANDATIONS

› Contacter ce client dans les 48h avec une offre de rétention personnalisée.

› Proposer une remise fidélité ou un avantage exclusif pour le réengager.

› Analyser ses tickets support pour identifier la source d'insatisfaction.

› Surveiller son activité sur les 30 prochains jours.

DONNÉES ANALYSÉES

Spending High

Fréquence 12 cmd

Ancienneté 78 j

Transactions

Support tickets

Saison printemps

Panier moyen €

Montant total €

Prédiction Churn Client E-commerce

24

Tests et Validation Apprentissages Cles

✎ Tests manuels (3 profils)

Profil Client	Probabilité	Niveau de Risque
Client VIP fidèle	8,7%	Risque Faible ✓
Client à risque	76,9%	Risque Critique ✓
Client moyen	40,3%	Risque Moyen ✓

💡 Apprentissages cl

🛡️ **Data Leakage**
Détection et suppression critique

✂️ **Feature Engineering**
8 nouvelles features dans le top 10

⚠️ **Préprocessing rigoureux**
Fit sur train uniquement

🚀 **GridSearch + Optuna**
Stratégie combinée efficace

👥 **KMeans**
Segmentation métier cohérente

Conclusion et Perspectives

Résultats finaux : **259 churners** correctement détectés sur 291 (**89% recall**)

Pipeline reproductible en **~2 minutes**

Perspectives

- Exploration de LightGBM/CatBoost
 - Calibration des probabilités
- Monitoring du data drift en production